01 / 作品价值

让材料生成流程可执行、可检查

MatPilot 与 MatterGen 使用流程及候选推荐对比

Harness 原生插件

真实少量生成

当日同池比较

插件的价值：把自然语言需求接到受控生成、结构核验和候选推荐，减少人工串接工具的工作。

本报告分别检查操作入口、推荐集合与真实 AI 调用。工程接入与结构筛选有据可查；人工节时和物性改善没有被预设为结论。本轮不含弛豫、DFT 或性质评价。

12

本轮真实生成候选

直接入口 + 插件入口

6 + 6

本轮两种执行入口

同配置、同批次大小

3 条

使用路径梳理

功能对照，非三臂统计试验

现有证据支持什么

- **流程能力已落地。** 在 Harness 中选择插件、保存配置；由统一工具完成计划、任务、结构检查和报告。
- **推荐结果可解释。** 按组成、空间群和计算规模的覆盖目标选出候选集合，保留每次选择依据。
- **本轮收益按实测陈述。** 保持相同类别覆盖，输入原子总数从原序选择的 51 降至 40；与最小规模基线选中集合相同。

主证据：2026-10-26 新生成、新同池排序与真实 AI 调用。历史数据仅在第 7 页作开发参考。

02 / 使用方式

三条路径，比较同一个任务

目标：生成少量候选，识别有效代表，输出下一步候选清单。

环节	直接使用 MatterGen	Harness + 通用工具	Harness + MatPilot
开始前	安装依赖与权重；理解检查点和命令行参数。	配置 Harness 与终端；代理仍需理解仓库、环境和命令。	安装原生插件；一次配置 Python 与后端。已有环境仍须正确安装。
提出需求	用户将研究目标转为模型支持的条件与参数。	自然语言输入；由 LLM 解释、写命令，正确性依赖其判断。	自然语言输入；能力查询 + 需求映射 + 计划校验，保留未支持条件。
启动与追踪	运行官方 CLI，检查输出目录与日志。	代理调用终端并读取日志；需组织运行状态。	提交统一任务、查询状态、绑定生成计划和产物。
检查与推荐	调用上游评估或自写分析；人工串接筛选规则。	LLM 可使用同等科学工具，但流程与证据需逐次组织。	批量检查与去重；推荐结果返回结构身份和明确理由。
交付	自行整理候选、参数、版本与限制。	代理汇总，其解释仍需与原始产物核对。	报告连接计划、候选及证据；可复算选择依据。

公平参照：MatterGen 官方仓库自身提供生成及评估工具，包括结构匹配与唯一性等评价。MatPilot 的增量是统一编排、任务约束、身份绑定与推荐集成；没有把上游已有能力写成插件独创。

用户仍需说明元素体系、数量、预算和研究目标。插件把 CLI 参数格式、状态追踪与候选文件整理封装为稳定工具；通用 LLM 也能编写脚本，本项目的增量是将流程内置并保留可复核证据。

路径图为功能审计，不是新用户用时实验；本轮新生成实测直接入口与插件入口；通用代理为能力路径说明，未伪装成当日三组对照。

03 / 本轮真实生成

小规模接通真实 MatterGen

本轮只验证生成与流程接入；未运行弛豫、DFT 或材料性质预测。

项目	直接入口	MatPilot 入口
本轮候选数	6	6
调用入口	官方 CLI（脚本启动）	生产 Service（脚本调用）
记录墙钟合计 / 秒	538.486	622.703
模型进程数	2	3
生成时 LLM 调用	0 次	0 次

这次实际验证的流程

01 **共同输入与执行边界**

同一 chemical_system 权重；Fe-Ni-O、batch_size=2、guidance=2.0；只生成。

02 **真实生成与产物绑定**

两条入口各 6 个，全体 12 个新 CIF 均登记哈希；未混入历史样本。

03 **插件交付完整流程**

生产 Service 串接计划、预算、任务状态、候选检查与报告；推荐对照见下一页。

两组是独立随机生成；本机固定版本 CLI 未提供 seed 接口，不能逐结构配对。插件组记录含轮询/CPU检查，且使用 3 个模型进程，对照为 2 个；上述耗时不能计算提速率。此处没有 LLM 驱动生成，真实 AI 推荐展示单独记录于第 6 页。

证据：artifacts/mattergen-usage-comparison-20261026.json；对应生成参数、CIF 哈希与工具轨迹见该文件。

04 / 当日结果整理对比

同一候选池，比较推荐集合

合并本轮两条入口的新候选；采用相同筛选标准，比较不同选取策略。

12

输入候选

本轮 MatterGen 真实生成

11

合格去重代表

完整组成 + 满占位 + 结构预检

4

推荐名额

各组相同数量

策略（均选 4 个）	组成	空间群	规模档	覆盖总数	原子数合计
合格池原顺序	4	4	2	10	51
合格池最小规模	4	4	2	10	40
随机 1,000 次均值	3.897	3.793	1.775	9.465	54.734
MatPilot 多样性	4	4	2	10	40

本轮观察与限制

本轮 12 个新候选中，1 个缺少目标元素；其余 11 个为共同合格代表。MatPilot 选出 D003、D005、P001、D001，保留 4 种组成、4 个空间群和 2 个规模档。

有改进，也有相同结果：相对合格池原顺序，覆盖保持不变，输入原子总数从 51 降至 40；但与“最小规模优先”选中的集合完全相同，仅次序不同。本轮没有证明多样性策略具有独有收益。

随机 1,000 次中有 60.2% 达到相同类别覆盖。所有强基线共享同一预检与去重；算法不知道候选来自哪条入口。原子数只是输入规模代理，不代表实际费用、提速或材料性能。未使用历史“优先弛豫”标签，结构预检通过仍待性质验证。

证据：artifacts/fresh-candidate-recommendation-comparison-20261026.json；新12候选及哈希已归档。

05 / 内置推荐方法

先确保可检查，再追求覆盖

“更好的结果”在此定义为：符合筛选规则、控制冗余、兼顾覆盖、理由可追溯。

01

验证身份与硬门槛

核对 CIF 与 SHA256；要求目标元素集合完整、显式满占位及基础几何通过。若使用已有“优先弛豫”标签，须由调用方明确提供，不能把结构预检冒充性质判断。

02

从坐标核验，再做结构去重

按声明容差分析空间群与结构等价；分析失败保留未知/排除，不默认写 P1。等价结构归到同一代表，避免重复占用名额。

03

以类别新增覆盖排序

组成、空间群、规模档等权；逐次优先选择带来更多未覆盖类别的候选。平局依次选择输入原子数较少者、候选 ID 较小者。

04

返回推荐，也返回为什么

输出名次、结构 ID/版本/哈希、新增覆盖类别和排除原因；保留完整池与已选清单，可重复计算同一结果。

工程增量：MG-Flow 已有多样性选择思路。本次将其整理成可调用的插件工具，加入身份校验、显式占位、未知对称性处理与稳定平局规则；不是首次提出多样性算法。

“优先弛豫”只是后续处理的候选优先级标签。 未经弛豫和性质评价，不能称为稳定、可合成、性能最优，也不能把空间群号码大小当作物理距离。

复算参数：占位容差 1e-6；最小接触距离 0.5 Å；空间群 symprec=0.1 Å、角容差 5°。规模档为 1-10 / 11-20 / 21+ 个输入原子。结构匹配：ltol=0.2、stol=0.3、angle_tol=5°。

方法版本、筛选门槛、归一化口径、平局规则和选中 ID 由同池对比工件记录，保留可复算输入。

06 / 本轮 AI 与实际入口

在已有 Harness 中直接选择

插件承担材料任务的稳定执行与证据整理，Harness 提供对话入口。



用户做什么	插件承担什么
安装并启用一次	在“已安装插件”选择材策 MatPilot；填写连接路径，保存后查询能力。
用自然语言描述任务	查询后端实际能力，把可支持条件形成计划；有缺失或冲突时明确澄清。
查看候选与推荐	批量检查后返回候选 ID、组成/空间群/规模、推荐理由及证据位置。
决定是否继续计算	当前只输出生成与推荐证据；后续弛豫或 DFT 需要单独任务与预算。

示例请求：“从这一批生成结果中，先保留组成完整、满占位、结构预检通过的去重代表，再选 4 个覆盖不同组成、空间群和计算规模的候选。给出每个入选理由和被排除的原因。”

本轮已部署 Python 核心 0.2.0.dev9，原生包仍为 0.2.0-dev.10；实测注册 10 个工具，新推荐调用成功。桌面保持 demo 生成模式，已登记的新真实候选可独立进行只读分析。首次热重连超时后重试成功。

本轮真实 AI 调用实例

DeepSeek Flash 先查询能力，再调用 recommend_candidates，返回 D003、D005、P001、D001。实测 2 次工具调用、3 次 API、7.318 秒（不含此前重连等待），新增保守核算 0.041854 元；只读处理本轮新候选，未新增生成、弛豫或 DFT。

这是一条真实工具调用，未做无插件对照或人工计时。最终文字曾把 0.5 Å 检查门槛写成“1 Å 内无过近接触”，因此保留原文并提示复核；工具结果不等于最终叙述完全正确。

界面图：2026-10-25 验收；当前部署见 native-recommendation-validation-20261026.json。新 AI 轨迹单独归档。

07 / 历史参考附录

历史记录用于解释开发选择

以下均非本轮新对照，不计入当日插件效果或新样本结果。

历史 r3：12 道开发题 × 3 组；真实 LLM、固定 CPU 回放。

组别	工具调用	墙钟合计 / 秒	API 核算 / 元
U：上游工具	87	147.912	2.274840
U+：修补上游	104	133.756	2.298286
M：MatPilot	94	159.031	2.842496

单题 D0101 曾出现 18 → 8 次工具调用；但全量 M 更慢、更贵。正常结束不等于答对，人工用时未测量，不能据此宣传普遍提速。

历史 128 候选：算法开发参考

策略（均选 12 个）	组成	空间群	规模档	覆盖总数	原子数合计
合格池原顺序	5	9	2	16	107
合格池最小规模	2	7	1	10	52
随机 1,000 次均值	8.145	8.610	1.997	18.752	112.341
历史 MG-Flow（同池）	10	9	2	21	109
MatPilot 多样性	12	12	2	26	105

历史池：128 → 显式优先标签 86 → 核验去重代表 66；各方案选 12 个。新推荐覆盖更广，但 105 个输入原子高于最小规模法的 52；24.3% 随机抽样更小。历史 MG-Flow 本来已有多样性方案。

用途：帮助确定规则与保留不利结果。该数据已经用于开发，不能当作新测试集，更不能把类别覆盖当作物性改善。主结论只取第 3-6 页当日证据。

历史来源：docs/study_plugin_effects.md；artifacts/candidate-recommendation-comparison-20261026.json。

08 / 复核与复现

证据能回到文件，结论能守住边界

本报告同时交付可复算工件，保留不利结果与尚未验证的部分。

证据层	对应工件 / 方法	可以证明
真实模型接入	mattergen-usage-comparison-20261026.json	命令与插件能调用真实生成；绑定参数、候选及产物。
当日同池推荐	fresh-candidate-recommendation-comparison-20261026.json	相同名额下的覆盖、冗余、排除原因与选中清单。
当日 AI 调用	harness-recommendation-validation-20261026.json	真实代理是否调用新工具、是否忠实解释新候选结果。
原生界面	native_plugin_acceptance.md	安装、配置保存、启停及工具生命周期。

读数之前，先看实验边界

- **本轮真实生成样本很少。** 两条入口的样本用于接通验证；没有以其差异推断生成质量。
- **推荐规则决定偏好。** 多样性适合有限预算探索，未必适合已有明确单一组成目标；专业用户可以调整或跳过。
- **“筛选优化”需要限定对象。** 能证明的是候选清单的组织与覆盖表现；材料性能提升仍需后续科学计算或实验。

来源与复核入口

1. Microsoft MatterGen 官方仓库：github.com/microsoft/mattergen
2. 项目与证据文档：github.com/fanjoy1177-spec/MatPilot
3. 本报告旁附机器可读证据清单；具体版本、命令、哈希与限制以工件为准。
4. 已从公开 manifest + CIF 独立 CPU 复算：候选表、选中清单、随机 1,000 次记录及推荐 JSON 字节一致。复算无 API / 模型调用。

结论以本轮新证据为准：插件串接生成、检查与推荐，减少需自行组织的环节；物性更好与普遍提速仍未被证明。